

Machine Learning

Ch6. Linear Model Selection and Regularization

김광수

2024년 2학기

Improving linear models

► Prediction accuracy

- 만약 $n \ll p$ 면, 선형모형 하에서 최소제곱추정량은 좋은 성능을 보임.
- 하지만 n 이 p 에 비해 그리 크지 않으면 추정에 변동성이 커짐. 과적합이 보통 발생하여 예측성능을 저하시킴.
- $n < p$ 인 경우, 유일한 추정량이 존재하지 않음.

► Model interpretability

- 반응변수에 별 다른 영향력이 없는 예측변수는 모형의 복잡성만을 초래함.
- 위와 같은 변수를 제거(계수를 0으로 만드는 것과 동일)함으로써 모형의 해석을 보다 용이하게 할 수 있음 / 변수가 고차원인 경우 해석만이 아니라 성능의 저하도 가져옴.

최소제곱추정에 대한 대안

- ▶ Subset selection: 전체 예측변수들 중 모형에 포함시킬 일부(부분집합)를 식별하고자 함.
- ▶ Shrinkage : p 개의 예측변수를 모두 포함하여 자료를 적합하되, 추정된 계수들에는 0을 향한 축소가 일어남. 이러한 축소는 추정량의 분산을 감소시키는 효과가 있음.
- ▶ Dimension reduction: p 개의 예측변수로 이루어진 공간을 $M < p$ 차원의 부분공간으로 정사영(projection)한 후 모형 적합.

Best subset selection

- ▶ k 개의 예측변수를 포함하는 모형 $\binom{p}{k}$ 개의 모형을 모두 적합하여 적절한 기준으로 가장 좋은 모형을 선택 ($\mathcal{M}_k$).
- ▶ $k = 0, 1, \dots, p$ 에 대하여 위 과정을 반복하여 $\mathcal{M}_0, \dots, \mathcal{M}_p$ 생성.
- ▶ 교차타당검증, C_p , AIC , BIC , adjusted- R^2 등을 이용하여 $\mathcal{M}_0, \dots, \mathcal{M}_p$ 중 가장 우수한 모형 선택.
- ▶ p 가 커짐에 따라 계산량이 매우 많아지는 단점이 있음.

Forward stepwise selection

1. 예측변수가 없는 모형 $\mathcal{M}_0$ 에서 출발.
2. $k = 0, \dots, p - 1$ 에 대하여 다음을 실행.
 - (a) $\mathcal{M}_k$ 에서 하나의 변수가 추가된 $p - k$ 개의 모형을 고려.
 - (b) 적절한 기준에서 가장 우수한 모형 선택 ($\mathcal{M}_{k+1}$).
3. 교차타당검증, C_p , AIC , BIC , adjusted- R^2 , 검증 데이터에서의 예측 오차 등을 이용하여 $\mathcal{M}_0, \dots, \mathcal{M}_p$ 중 가장 우수한 모형 선택.

Forward stepwise selection

▶ $1 + \sum_{k=0}^{p-1} (p - k) = 1 + p(p + 1)/2$ 번의 모형 적합 필요.

▶ Step 2(b)와 Step 3의 기준은 다르게 설정이 되는 것도 가능함.

▶ 계산량은 경감되나 best model을 선택할 수 있다는 보장은 없음.

Backward stepwise selection

1. 예측변수가 모두 포함된 모형 $\mathcal{M}_p$ 에서 출발.
2. $k = p, p - 1, \dots, 1$ 에 대하여 다음을 실행.
 - (a) $\mathcal{M}_k$ 에서 하나의 변수만을 제외한 k 개의 모형을 각각 고려.
 - (b) RSS 혹은 R^2 의 관점에서 가장 우수한 모형 선택 ($\mathcal{M}_{k-1}$).
3. 교차타당검증, C_p , AIC , BIC , adjusted- R^2 , 검증 데이터에서의 예측 오차 등을 이용하여 $\mathcal{M}_0, \dots, \mathcal{M}_p$ 중 가장 우수한 모형 선택.

Backward stepwise selection

- ▶ Forward와 비슷하나 진행방향이 반대.
- ▶ $1 + \sum_{k=1}^p k = 1 + p(p+1)/2$ 번의 모형 적합 필요.
- ▶ 계산량은 경감되나 best model을 선택할 수 있다는 보장은 없음.

Hybrid approaches

- ▶ forward와 backward의 장점을 살리되 모형의 복잡도가 순증가/순감소하는 방식으로 찾는 단점을 보완.
- ▶ 기본적으로 forward의 방식을 취하되 새로운 변수가 하나 추가된 후 모형적합에 더이상 도움이 되지 않아 제거가 필요한 변수가 있는지 탐색.

최적모형선택

- ▶ 최적모형 선택을 위해서는 test error에 대한 추정이 필요한데 여기에는 두 가지 접근법이 있을 수 있음.

- 교차타당검증을 이용하여 직접적으로 test error를 추정 (5장에서 다루었음).

- training error에 과적합 등에 따른 편의를 고려한 보정을 가하는 방식으로 간접적으로 test error를 추정.

평가측도

- ▶ RSS, R^2 등은 모형의 복잡도에 따라 단조적으로 변하는 측도이므로 최적모형 선택에 도움이 되지 않음.
- ▶ training error를 모형의 크기(복잡도 혹은 모수의 개수)에 대하여 보정한 측도들 활용.
- ▶ 다음과 같은 4가지 측도를 소개 : C_p , Akaike information criterion (AIC), Bayesian information criterion (BIC), adjusted- R^2

- ▶ p 개의 예측변수를 포함한 모형에서 test MSE에 대한 추정량으로 다음과 같은 통계량이 제안됨.

$$C_p = \frac{1}{n}(RSS + 2p\hat{\sigma}^2)$$

참고로 $E[(y' - x^\top \hat{\beta})^2] - E[(y - x^\top \hat{\beta})^2] = 2p\hat{\sigma}^2$ 이며, 여기에서 y' 은 평가데이터에서 y 는 훈련데이터에서 나옴.
여기서 $\hat{\sigma}^2$ 은 오차항의 분산 추정치임.

- ▶ RSS 는 모형이 복잡해지면 감소하고 $2p\hat{\sigma}^2$ 은 증가함
- ▶ 작을수록 우수한 모형으로 평가함.

AIC(Akaike Information Criterion)

▶ 최대가능도추정법에 의한 모형적합에 대하여 정의됨.

▶ 오차항이 정규분포인 경우 AIC는 다음과 같이 정의됨.

$$AIC = -2 \log \hat{L} + 2p \propto n \log \hat{\sigma}^2 + 2p$$

▶ 불필요한 상수항은 생략되었음.

▶ 오차항이 정규분포이고 σ^2 를 아는 경우 C_p 와 같은 모형을 선택함.

BIC(Bayesian Information Criterion)

▶ 베이زي안의 관점에서 유도됨.

▶ p 개의 예측변수를 가지는 최소제곱추정의 경우 다음과 같이 정의됨.

$$BIC = -2 \log \hat{L} + (\log n)p \propto n \log \hat{\sigma}^2 + (\log n)p$$

▶ 불필요한 상수항은 생략되었음.

▶ 작을수록 우수한 모형으로 평가.

▶ $n > 7$ 면 $\log(n) > 2$ 이므로, 상대적으로 작은 모형을 선호하는 경향이 있음.

Adjusted- R^2

▶ R^2 에 모형의 크기에 따른 적절한 보정 부여.

▶ 다음과 같이 정의됨.

$$Adjusted\ R^2 = 1 - \frac{RSS/(n - p - 1)}{TSS/(n - 1)}$$

▶ 클수록 우수한 모형으로 평가.

▶ $RSS/(n - p - 1)$ 을 최소화시키는 것과 동치.

- ▶ C_p , AIC , BIC 는 이론적인 정당성이 존재하나 adjusted- R^2 는 이해가 쉬운 반면 이론적인 배경은 빈약함.
- ▶ C_p , AIC , BIC 측도들은 선형모형 뿐 아니라 좀 더 일반적인 형태의 모형 하에서도 적절히 정의될 수 있으며 모형 선택에 활용될 수 있음.
- ▶ 과거에는 보정측도들을 널리 사용되었으나 계산능력의 향상으로 교차타당검증법도 매우 대중적이 되었음.

예 : Credit 데이터셋 (11개의 예측변수)

▶ best subset selection




Figure 1: R^2 and RSS

예 : Credit 데이터셋 (11개의 예측변수)

▶ Best subset selection




Figure 2: C_p , BIC and R_{adj}^2

예 : Credit 데이터셋 (11개의 예측변수)

▶ Best subset selection




Figure 3: *BIC*와 교차타당검증

One-standard-error rule

- ▶ 교차타당검증에는 데이터셋 분할에 따른 변동성이 존재할 수 있음.
- ▶ test MSE의 표준오차(e)를 추정한 후 최적으로 판명된 모형의 test MSE에서 e 이내의 test MSE를 가지는 모형들은 대략 비슷한 성능을 보이는 것으로 간주함.
- ▶ 즉, test MSE의 최솟값 $\pm e$ 이내에서 test MSE를 가지고 있는 모형들 중 가장 단순한 모형을 최종 모형으로 선택.

Shrinkage methods

- ▶ Subset selection은 전체 예측변수의 부분집합들에 대해서 최소제곱추정량을 구하고 적절한 측도에 의한 비교를 수행하는 방법임.
- ▶ 대안적인 방법으로 전체 예측변수를 포함하여 추정하되 계수추정치를 regularizes 혹은 shrinks towards zero 하는 방식으로 추정할 수 있음.
- ▶ 위와 같은 방식으로 추정량의 분산을 획기적으로 줄일 수 있음이 알려져 있음.
- ▶ 가장 대표적인 두 가지 방식은 Ridge와 Lasso 추정량.

Ridge regression

- ▶ 선형모형에서 계수의 최소제곱추정량은 다음을 최소화시키는 것으로 정의.

$$RSS = \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2$$

- ▶ Ridge 추정량은 최소제곱법과 매우 유사하나 shrinkage penalty를 추가로 고려하여 최소화

$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

여기서 $\lambda \geq 0$ 는 penalty parameter 혹은 tuning parameter.

Ridge 추정량 ($\hat{\beta}_{\lambda}^R$)

- ▶ Penalty term의 존재가 너무 큰 $\hat{\beta}_{\lambda}^R$ 값이 주어지는 것을 막음
- ▶ 즉, RSS의 크기를 작게하는 적절한 크기의 $\hat{\beta}_{\lambda}^R$ 가 결정됨
- ▶ $\lambda = 0$ 이면, 최소제곱추정과 같아지고 $\lambda \rightarrow \infty$ 이면 $\hat{\beta}_{\lambda}^R \rightarrow 0$ 이 됨. 즉, λ 는 축소(shrinkage)의 정도를 결정해주는 모수이며 세심한 선택(혹은 추정)이 필요함.
- ▶ 교차타당검증법 등을 이용하여 λ 를 선택하는 경우가 많음.

Ridge 추정량




Figure 4: λ 에 따른 축소

왜 Ridge 추정량인가?

- ▶ λ 의 증가는 모형의 유연성의 감소로 이어짐. 즉, bias의 증가 variance의 감소가 일어남.
- ▶ 최소제곱추정량의 분산이 매우 큰 경우에는 이러한 고려가 전체 MSE의 감소를 가져올 수 있음.
- ▶ Ridge 추정량은 편의추정량임. 즉, 불편성을 포기하는 대신 variance에의 감소를 얻겠다는 것임.
- ▶ 보통 예측변수들 사이의 상관성이 클 때 Ridge의 이점이 발휘됨.
- ▶ Ridge 추정량은 scale-invariant 하지 않음. 즉, 예측변수들의 표준화를 사전에 실시하는 것이 추천됨.

Lasso regression

- ▶ Ridge 추정량은 예측력의 향상은 가져올 수 있으나 모든 예측변수가 모형에 포함되므로 모형 해석력에서는 장점이 없음.
- ▶ Lasso는 예측력의 향상 뿐 아니라 예측변수의 선택에 따른 모형의 단순성을 가져올 수 있는 장점이 있는 방법.
- ▶ Lasso 추정량은 Ridge와 매우 유사하나 다음과 같이 shrinkage penalty의 형태가 다르게 하여 최적화를 함.

$$\sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

여기서 $\lambda \geq 0$ 는 penalty parameter 혹은 tuning parameter.

Lasso 추정량

- ▶ Ridge와 같이 0을 향한 축소가 일어남
- ▶ Ridge와 달리 일부 계수는 정확히 0으로 추정하여 자동적으로 변수선택이 일어남
- ▶ Best subset selection과는 달리 단 한 번의 적합만이 필요
- ▶ l_1 norm을 사용하는 축소추정법으로 sparse model을 생성한다고 표현함
- ▶ Ridge와 마찬가지로 λ 는 축소의 정도를 결정해주는 모수로 세심한 선택이 필요함

Lasso 추정량




Figure 5: λ 에 따른 축소

Ridge와 Lasso의 또다른 표현

▶ 두 추정법은 다음과 같은 최소화와 동치임이 알려져 있음.

▶ Ridge

$$\text{minimize } \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 \quad \text{subject to } \sum_{j=1}^p \beta_j^2 \leq s$$

▶ Lasso

$$\text{minimize } \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 \quad \text{subject to } \sum_{j=1}^p |\beta_j| \leq s$$

왜 Lasso는 sparse model을 생성하는가?




Figure 6: Ridge(right) vs Lasso(left) when $p = 2$

Ridge and Lasso

- ▶ 예측력의 관점에서 둘 중 어느 하나가 항상 낫다고 보기는 어렵다.
- ▶ 실제로 소수의 예측변수들만이 반응변수에 영향력이 있다면 Lasso가 우수하며 예측변수들 간의 상관관계가 높다면 성능이 다소 저하됨.
- ▶ 변수들 간의 상관관계가 높다면 Ridge가 우수하며 독립성이 강한 고차원 예측변수에서는 다소 불리할 수 있음.

λ 의 선택?

- ▶ 교차타당검증법에 의한 선택이 일반적임.
- ▶ λ 의 grid를 선택하고 가능한 모든 값 중 가장 우수한 λ 를 선택.
- ▶ 선택된 λ 에 대하여 모든 자료에 대하여 축소추정을 실시.
- ▶ 계산량은 grid의 개수에 의존함. 계산량의 경감을 위하여 경로 알고리즘 등이 제안되기도 함.

λ 의 선택?






Figure 7: tuning parameter

Example : $p = 45, n = 50$

▶ 45개 중 2개만이 실제로 반응변수에 영향 (signal/noise variables)



Dimension reduction methods

- ▶ 예측변수들의 변환을 통해 새로운 변수들을 생성한 후 모형적합.
- ▶ 새로 생성된 변수들의 차원은 원 변수들의 차원보다 작아지도록 함.
- ▶ 원 변수 $X_1, \dots, X_p$ 에 대하여 다음과 같은 $M < p$ 개의 변수를 생성.

$$Z_m = \sum_{j=1}^p \phi_{jm} X_j, \quad m = 1, 2, \dots, M$$

- ▶ $Z_1, \dots, Z_M$ 으로 선형모형 적합.
- ▶ 대표적인 두 방법 주성분회귀와 부분최소제곱법을 소개.

주성분회귀 (Principal component regression)

- ▶ 예측변수의 공간으로부터 M 개의 주성분을 추출한 후 선형모형 적합.
- ▶ p 개의 예측변수들이 모두 사용됨.
- ▶ 차원축소 과정에서 반응변수와의 관련성은 고려되지 않음.
- ▶ 표준화 이후 주성분회귀를 수행하는 것이 추천됨.

부분최소제곱법 (Partial least squares)

- ▶ 순차적으로 변환변수들을 생성해 내는 방식.
- ▶ $Z_1 = \sum_{j=1}^p \phi_{j1} X_j$ 에서 ϕ_{j1} 를 $Corr(Y, X_j)$ 에 비례하도록 세팅함. 즉, 반응변수와 상관성이 큰 예측변수에 높은 가중치를 두는 방식으로 변환변수를 정의.
- ▶ Z_1 과 예측변수들간의 회귀모형적합을 통해 잔차를 생성 (Z_1 에 의한 부분이 제거된 정보로 이해).
- ▶ $Z_2, \dots, Z_M$ 을 Z_1 과 같은 방식으로 생성해 냄.
- ▶ 차원축소 과정에서 반응변수와의 관련성이 고려됨.
- ▶ Ridge나 PCR 대비 성능이 그리 뛰어나지는 않은 경우가 많음.