

Machine Learning

Ch8. Tree-based Methods

김광수

2024년 2학기

의사결정나무 (Decision trees)

- ▶ 나무모형은 예측변수들의 공간(예측변수가 가질 있는 값들의 집합)에 대한 층화적 분할에 근거한다.
- ▶ 주어진 관측치에서의 예측값은 해당 관측치가 속한 예측변수의 영역 (분할된 공간)에서 반응변수들의 평균값으로 주어지는 것이 보통이다.
- ▶ 나무모형은 간단하고 해석에서 장점이 있다.
- ▶ 반면, 다른 기계학습 방법들에 비해 좋은 성능을 보이지 못하는 경우가 많다.
- ▶ 이를 개선하기 위하여 여러 나무 모형을 결합하여 하나의 예측값을 주는 방법들이 제안되어 있다.
- ▶ 회귀모형, 분류모형에 모두 적용될 수 있다.

Regeression trees

- ▶ 야구선수의 연봉예측: 선수경력과 직전 해의 안타수가 설명변수.

$$\log(\text{Salary}) \sim \text{Years} + \text{Hits}$$



Figure 1: Regression tree

Regeression trees

▶ 예측변수들 공간의 분할.




Figure 2: 분할

Regression trees

- ▶ 분할된 공간 혹은 나무에서의 최하단 부분을 terminal nodes 혹은 leaves라 지칭한다.
- ▶ 선수경력이 연봉에 가장 중요한 요소가 된다.
- ▶ 경력이 오래된 선수들은 안타수가 연봉에 영향을 미치는 것으로 보인다.
- ▶ 경력이 7년이고 직전 해에 78개의 안타를 때려낸 선수의 예측연봉은?
 R_2 부분의 평균연봉으로 추정가능하다.

공간분할의 원리 (1)

- ▶ Binary splitting: 기본적으로 전체 공간을 하나의 예측변수를 기준으로 두 공간으로 분할한다.
- ▶ 이러한 과정을 반복하여 여러개의 공간으로 분할(즉, tree 생성): 분할할 때마다 사용되는 변수는 달라진다.
- ▶ 단. 하위분할시에는 전체공간이 아니라 이미 분할된 공간에 binary splitting을 적용함: 층화적 분할.
- ▶ 적절한 stopping rule에 따라 분할을 중지한다.

공간분할의 원리 (2)

- ▶ 고려할 수 있는 변수들과 분기점들 중 가장 큰 제곱합의 감소를 가져다 주는 변수와 분기점을 선택한다.

$$\sum_{i \in R} (y_i - \bar{y})^2 - \sum_{k=1}^2 \sum_{i \in R_k} (y_i - \bar{y}_k)^2$$

- ▶ 결국 아래의 RSS가 최소화되는 예측변수 및 예측변수의 값들을 선택하는 것을 목표로 한다.

$$RSS = \sum_{j=1}^J \sum_{i \in R_j} (y_i - \hat{y}_{R_j})^2$$

where $\hat{y}_{R_j}$ is the mean response within R_j . 여기에서 R_j 는 terminal node의 영역들임.

Pruning

- ▶ 앞선 과정을 통해 생성된 나무모형은 예측성능은 좋을 수 있지만 과적합 문제가 발생할 수 있다.
- ▶ 나무의 크기는 곧 모형의 복잡도와 연결됨. 즉, 적절히 모형을 단순화시켜줄 필요가 있다.
- ▶ 단순화된 나무는 해석도 더 간단해 질 뿐 아니라 test error도 줄여줄 수 있다.
- ▶ 여러 방법이 존재.
 - RSS의 감소가 특정수준 이하로 떨어지면 중단하는 방법: 이후에 RSS에 큰 감소를 불러일으키는 분할을 무시하게 될 수 있음.
 - 더 선호되는 방법은 나무를 매우 크게 키운 뒤 적절히 가지치기하여 단순화시키는 방법. 보통 test error를 작게 하는 subtree를 적절한 알고리즘을 통하여 찾음.


Cost complexity pruning

- ▶ α 의 적절한 grid를 선택하고 각 α 에 대하여 다음을 최소화 시키는 나무를 찾는다.

$$\sum_{m=1}^{|T|} \sum_{x_i \in R_m} (y_i - \hat{y}_{R_m})^2 + \alpha |T|$$

- ▶ k -fold cross-validation에 의하여 test error를 최소화시키는 α 의 값 혹은 나무를 찾는다.
- ▶ 선택된 α 에 대응되는 나무가 최종 선택되는 모형을 선택한다.
- ▶ α 는 나무의 복잡도를 control하는 모수으로써 Lasso에서의 λ 와 비슷한 역할을 한다.

Unpruned tree



training, CV and test error




Figure 4: 모형복잡도에 따른 오차

Classification trees

- ▶ Regression tree와 유사성이 큼.
- ▶ 분할된 공간에서 혹은 node에서 반응변수의 값이 가장 많이 나타나는 class로 예측한다.
- ▶ 예측확률은 해당 공간에 포함된 관측치수 대비 관심있는 class의 비율로 결정한다.
- ▶ 공간분할시 RSS 대신 다른 측도를 사용한다.

Measures for splitting

- Classification error rate

$$E = 1 - \max_k(\hat{p}_{mk})$$

where $\hat{p}_{mk}$ is the proportion of k -th class.

- Gini index

$$G = \sum_{k=1}^K \hat{p}_{mk}(1 - \hat{p}_{mk})$$

- Entropy

$$D = - \sum_{k=1}^K \hat{p}_{mk} \log \hat{p}_{mk}$$

Measures for splitting

- ▶ Classification error rate는 최대값에만 의존하여 sensitive한 측도가 아니다.
- ▶ Gini index와 Entropy가 주로 사용됨: 즉 하나의 노드가 두 개의 노드로 분할될 때, 가장 Gini index 또는 Entropy가 많이 줄어드는 경우를 선택한다.
- ▶ 위 두 측도는 해당 공간의 순도가 높을 수록 (즉, 관측치들이 같은 class들로 대부분 이루어져 있을 수록) 0에 가까운 값을 가지게 된다.
- ▶ 즉, 불순도(impurity)를 최소화시키는 방향으로 분할이 이루어진다.

Classification tree





Figure 5: Heart data

Tree vs Linear models

- ▶ Linear models

$$f(X) = \beta_0 + \sum_{j=1}^p X_j \beta_j$$





- ▶ Regression trees

$$f(X) = \sum_{m=1}^M c_m I(X \in R_m)$$

where R_m is the partition of predictor space.

- ▶ 실제 관계가 선형이 아니면 나무모형이 우수하다.

Tree vs Linear models



나무모형의 장단점

▶ 장점

- 모형에 대한 해석과 설명이 매우 직관적이고 간단하다.
- 시각적으로 표현이 용이하다.
- 예측변수에 범주형 변수가 있을 때 dummy variable 을 도입할 필요가 없다.

▶ 단점

- 예측성능이 좋지 못한 경우가 많다.
- 모형의 분산이 커서 robust 하지 않은 경우가 많다. 즉, data가 조금만 바뀌어도 생성되는 나무모형이 완전히 딴판이 되기도 한다.

Ensemble methods

- ▶ 단일나무모형은 큰 분산을 가지는 경우가 많아 좋은 예측성능을 기대하기 어려운 경우가 많다.
- ▶ 즉, 데이터의 작은 변화가 추정모형에의 큰 변화를 초래할 수 있다.
- ▶ 단일나무모형의 성능 향상을 위하여 여러 나무모형을 고려하는 방식이 다양하게 제안되었다.
- ▶ 앞으로 소개되는 방법들은 나무모형에 빈번하게 적용되기는 하지만 다른 학습모형에도 일반적으로 적용이 가능하다.

Bagging : Bootstrap aggregation

- ▶ 분산이 σ^2 인 분포를 가지는 확률변수 Z 를 고려해 보자. 만약, IID random sample $Z_1, \dots, Z_n$ 을 같은 분포로부터 생성해 낼 수 있다면, 이의 표본평균 $\bar{Z}$ 의 분산은 σ^2/n , 즉, $1/n$ 만큼 줄어든다.
- ▶ 만약, 모집단으로부터 여러 개의 훈련자료를 얻을 수 있고 이로부터 여러 개의 모형 $\hat{f}^1, \dots, \hat{f}^B$ 을 얻을 수 있다면, 이로부터 주어지는 averaged prediction에 의해 모형의 분산을 줄일 수 있다.

$$\hat{f}_{avg}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^b(x)$$

- ▶ 보통은 한 set의 자료만이 주어지게 되므로 위 방식은 직접 적용이 불가능하다.
- ▶ 대신 Bootstrap을 이용하여 한 set의 자료로부터 여러 개의 훈련자료를 생성해 낼 수 있다.

Bootstrapping

- ▶ $X_1, \dots, X_n$ 이 어떤 모집단으로부터의 IID random sample 이라 할 때, 이로부터 복원추출을 통해 같은 size의 표본을 만들어낼 수 있다.

- ▶ 이렇게 얻어진 자료를 Bootstrap sample 이라 한다.

$$X_1^*, \dots, X_n^*$$

- ▶ 위와 같은 과정을 B 번 반복하면 총 B 개의 Bootstrap sample이 얻어진다. 각 sample을 훈련자료로 간주하여 얻게 되는 함수를 $\hat{f}^{*,1}, \dots, \hat{f}^{*,B}$ 라 하면, 최종 예측함수는

$$\hat{f}_{bag}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*,b}(x)$$

와 같이 구성할 수 있다. 이를 bagging이라 한다.

Bagging의 효과

- ▶ Bagging 수행시에는 각 나무들을 pruning하지 않아도 좋다. 즉, 각 나무들의 분산이 커지더라도 편의를 작게 가지도록 하는 것이다.
- ▶ 여러 나무들을 averaging 하는 과정에서 분산에의 획기적인 향상이 나타난다.
- ▶ bagging은 여러 회귀방법들에서 예측력의 향상을 가져올 수 있지만, 특히 나무모형에서 그 효용이 매우 크다.


Bagging for classification

- ▶ 분류문제에서는 예측값이 class로 주어지므로 이를 평균을 내는 것은 의미가 없다.
- ▶ 대신 B 개의 개별나무들의 예측값 중 가장 다수를 차지하는 class로 최종 예측값을 할당한다. 이를 Majority voting 이라 한다.

Out-of-Bag error estimation

- ▶ Bagging 수행시 특정 나무의 적합에 사용되지 않는 관측치들이 평균적으로 전체의 약 1/3 정도 됨이 알려져 있다.
- ▶ i 번째 관측치에 대한 test error를 추정하고자 할 때, B 개의 나무모형 중 i 번째 관측치를 적합에 사용하지 않은 약 $B/3$ 개의 나무들에 의한 예측치를 이용할 수 있다.
- ▶ 모든 관측치에 대하여 위와 같은 과정을 수행하여 최종 test error를 추정한다.
- ▶ Out-of-Bag 방법을 이용한 test error 추정을 이용하면 교차타당검증법 등 계산이 많이 필요한 절차를 피할 수 있다.


Example : Heart data



Variable importance measure

- ▶ 다른 형태의 여러 나무를 결합하면 모형을 해석하는 것은 거의 불가능해진다.
- ▶ 어떤 변수에 대하여 어떤 규칙에 따라 예측변수들의 공간분할이 이루어져 있는지도 알기 어렵다.
- ▶ 대안적으로, 나무들을 생성할 때 어떤 변수들이 RSS 혹은 Gini index등에 큰 감소를 가져왔는지를 요약한 값으로 변수의 중요도를 판단할 수 있다.
- ▶ B 개의 모형에 대한 평균적인 기여 정도로 변수의 중요도를 평가하게 된다.

Example : Heart data



상관성과 averaging에 따른 분산 감소

- ▶ Bagging으로 예측력의 향상을 기대할 수 있는 이유는 분산의 감소를 가져오기 때문이다.
- ▶ 만약 예측변수들 중 아주 강력한 소수의 예측변수들이 존재하여 나무모형 생성시 대부분 이 변수들을 기준으로 분할이 이루어진다고 가정하자.
- ▶ 결과로써 얻어지는 B 개의 나무모형은 유사성이 꽤나 크게 될 것이다. 즉, 모형들 간의 correlation이 클 것이다. 이는 final model의 예측력 향상에 부정적인 영향을 미치게 된다.
- ▶ X_1, X_2 가 평균이 0이고 분산이 1인 확률변수라 하자. 둘 사이의 상관계수가 각각 (1) 0 (2) 0.8 인 경우 두 확률변수의 표본평균의 분산은 각각 (1) 0.5 (2) 0.9 가 된다. 즉, 둘 사이에 양의 상관관계가 강하면 averaging에 의한 분산 감소량이 줄어든다.

Random forests

- ▶ Random forests는 Bootstrap에 의해 생성되는 나무들간의 상관성을 제거(de-correlation)함으로써 최종예측모형의 분산을 획기적으로 감소시키고자 하는 방법이다.
- ▶ 소수의 강력한 예측변수에 의해 모든 나무모형이 유사해지는 것을 막기 위하여 매번 분할시마다 p 개의 예측변수 중 일부인 $m < p$ 개의 예측변수들만 분할기준의 후보로 삼는다.
- ▶ 즉, 예측변수들을 의도적으로 일부 배제함으로써 나무모형들의 다양성을 확보할 수 있다. 이는 final model의 예측력 향상으로 이어질 수 있다.
- ▶ 회귀모형에서는 $m = p/3$, 분류모형에서는 $m = \sqrt{p}$ 가 흔히 사용된다.

Example : gene expression data

